

Improving Language Understanding by Generative Pre-Training

■ Date	@March 24, 2025
■ Keyword	Fine-tuning Language Representation NLP Pre-training Transformer
■ Status	Done
■ URL	https://cdn.openai.com/research-covers/language-unsupervised/language_understanding_paper.pdf

Overview

대규모의 unlabeled text 집합은 풍부하지만 task specific task를 위한 labeled data는 매우 적다

→ 다양한 종류의 unlabeled data를 가지고 Language model을 generative pre-training 하고 discriminative fine-tuning을 통해 다양한 NLP task에서 큰 성능 향상을 얻을 수 있다.

fine-tuning 시에 task-aware input transformation을 사용함으로써 model architecture에 최소한의 변화만 주며 효과적으로 specific task로 transfer할 수 있도록 한다.

Introduction

대부분의 딥러닝 모델들은 매우 많은 labeled data를 필요로 하지만 그러한 데이터는 매우 부족하다.

Unlabeled data를 사용할 경우, 단어 수준의 정보만 얻게된다.

→ Unsupervised pre-training과 supervised fine-tuning을 결합해 language understanding task에 대해 semi-supervised approach를 탐구한다.

두 단계의 training 절차를 사용한다.

1. Unlabeled data에 대해 language modeling objective를 사용해 nn model의 initial parameter를 학습하도록 한다.
2. 이렇게 얻은 parameter를 target task에 해당하는 supervised objective를 사용해 적용시킨다.

우리는 natural language inference, question answering, semantic similarity, text classification task에 대해 평가한다.

▼ Related Work

1. Semi-supervised learning for NLP

GPT는 semi-supervised learning의 한 종류이다.

초기 접근 방식은 unlabeled data를 사용해 단어 수준, 구문 수준의 통계를 계산하고 이를 지도 학습 모델의 feature로 활용한다.

또한 pre-trained word embedding이 다양한 nlp 작업에 기여를 했으나 주로 단어 수준의 정보를 전이하는데 중점을 둔다.

2. Unsupervised pre-training

이러한 접근의 목적은 좋은 initialization point를 찾는 것이다.

연구에 따르면 이러한 pre-training은 regularization의 역할을 한다는 것이 밝혀졌다.

본 논문에서 선택한 transformer network는 더 긴 linguistic structure를 파악하게 한다.

3. Auxiliary training objectives

Auxiliary language modeling object를 target task objective에 추가함으로써 sequence labeling task에서 성능 향상을 보인다는 연구가 있다.

본 논문에서도 auxiliary objective를 사용한다.

▼ Before GPT

1. Word2Vec

CBOW, Skip-gram 방식을 사용해 주변 단어로 중심 단어를 예측하는 embedding 방법

단어를 연속적인 저차원 벡터로 표현해 의미적, 문법적 관계를 포착

2. Seq2Seq

Encoder RNN이 입력 문장을 읽어 고정 벡터로 요약하고 decoder RNN이 해당 벡터를 토대로 번역을 생성하는 모델하고 Dec

LSTM을 활용한 방법

3. Attention

디코더가 단어를 생성할 때 입력 문장의 모든 단어를 복, 가중치를 결정하는 방식으로 작동하는 모델

4. ELMo

문맥에 따라 동적으로 변하는 임베딩을 생성하기 위해 사전 훈련된 언어 모델을 사용하는 embedding 방법

Framework

두개의 training 단계를 따른다. (1)매우 큰 text 집합에 대해 high-capacity language model을 학습 (2)fine-tuning stage이자 labeled data를 활용해 각각의 task를 수행하도록 하는 단계이다.

1. Unsupervised pre-training

실험에서 Multi-layer Transformer decoder를 사용한다. 이 모델은 multi-headed self-attention 작업을 input context token들에 대해 적용하고 position-wise feedforward layer를 통해 target token에 대해 output distribution을 생성한다.

$$\begin{aligned}h_0 &= UW_e + W_p \\h_l &= \text{transformer_block}(h_{l-1}) \forall i \in [1, n] \\P(u) &= \text{softmax}(h_n W_e^T)\end{aligned}$$

$$L_1(\mathcal{U}) = \sum_i \log P(u_i | u_{i-k}, \dots, u_{i-1}; \Theta)$$

2. Supervised fine-tuning

Pre-training 작업을 마친 후 supervised task에 대해 parameter를 적응시킨다. ⇒ transfer를 달성

Language modeling을 auxiliary objective로 추가할 경우 훈련에 아래와 같이 도움이 된다.

1. Supervised model의 일반화를 향상시킨다.
2. 수렴을 가속화한다.

$$P(y|x^1, \dots, x^m) = \text{softmax}(h_l^m W_y).$$

$$L_2(\mathcal{C}) = \sum_{(x,y)} \log P(y|x^1, \dots, x^m).$$

3. Task-specific input transformation

Task 마다 구조를 바꾸는 기존의 방식은 task마다 맞춤 설계가 필요하고, 추가적인 architecture 구성 요소에 대해 transfer learning을 활용하지 못하게 한다.

그렇기 때문에 본 논문에서는 우리의 pre-trained model이 다룰 수 있도록 input을 ordered sequence 형태로 설계하는 **traversal-style** 접근 방식을 사용한다.

⇒ 기존에는 모델 아키텍처, 학습 방법, 학습 목표를 수정해 task-specific의 성능을 향상시켰다면 GPT는 task를 수정한다.




Figure 1: **(left)** Transformer architecture and training objectives used in this work. **(right)** Input transformations for fine-tuning on different tasks. We convert all structured inputs into token sequences to be processed by our pre-trained model, followed by a linear+softmax layer.

Experiments

Setup

Model specifications

- 12-layer decoder-only transformer with masked self-attention heads

Fine-tuning details

- Unsupervised pre-training의 hyperparameter setting을 사용한다.

BookCorpus: 7000권의 출판되지 않은 책을 포함하는 데이터셋

Supervised fine-tuning

Natural Language Inference

문장의 쌍을 읽고 그 두개 문장의 관계를 추론하는 task

⇒ GPT 모델이 대규모의 NLI dataset일 때 좋은 성능을 내는 것으로 보아 multi-task training이 성능 향상에 도움이 될 것이라는 결론이 나온다.

Question answering and commonsense reasoning

⇒ 이전까지 최고의 성능보다 GPT가 좋은 성능을 보였다.

Semantic Similarity


⇒ 세개 중 두개의 Semantic Similarity task에 대해 최고의 성능을 보였다.

Classification

⇒ 모든 task에 대해 좋은 성능을 보였다.

Analysis

Impact of number of layers transferred



Embedding을 Transfer하면 성능 향상에 큰 기여를하고 각 Transformer 레이어를 추가로 전이할수록 성능이 더 향상된다.

⇒ Pre-training model에서 학습된 정보들이 target task를 푸는 데 도움을 준다.

Zero-shot Behaviors

왜 transformer에서 language model pre-training이 효과적인가?

우리는 supervised fine-tuning 없이, 생성형 언어 모델만을 사용해 task를 수행 가능한 heuristic 솔루션들을 설계했다.

Transformer는 training할 수록 결과가 좋아지고 LSTM은 결과가 튀며 transformer가 더 전이에 유리함을 보여준다.

⇒ Fine-tuning 방식이, 다양한 NLP task에서의 성능을 향상시킨다는 것을 보여준다.

Ablation studies

- Auxiliary objective가 NLI task와 QQP의 성능향상에 도움이 된다.
- 큰 데이터셋일수록 Auxiliary objective로 인한 성능향상이 뚜렷하다.
- 모든 task에 대해 적은 pre-training 과정은 성능을 모든 task에 대해 감소시킨다.

▼ 한계점

- 모델 규모: 라벨링 작업이 필요하고 모델 크기가 비교적 작음 ⇒ GPT-2 탄생

Summary

- GPT-1은 generative pre-training과 discriminative fine-tuning을 결합해, task-agnostic model로 다양한 언어 이해 과제를 성공적으로 해결할 수 있는 프레임워크를 제안했다.
- 긴 연속 텍스트로 구성된 방대한 코퍼스에 대해 사전 학습함으로써, world knowledge와 long-range dependencies을 이해하는 능력을 갖추게 되었다.
- 이렇게 학습된 모델은 질문 응답, 문장 유사도, 함의 관계 추론, 텍스트 분류 등 discriminative tasks에 효과적으로 전이되며, 총 12개 과제 중 9개에서 최선 성능을 달성했다.
- 이는 unsupervised learning이 지도 학습 기반 과제 성능을 크게 향상시킬 수 있음을 보여준다.
- 궁극적으로 이 연구는 자연어 이해뿐 아니라 **다른 영역의 비지도 학습 연구에도 영감을 줄 수 있는 가능성**을 제시한다.