

BART: Denoising Sequence-to-Sequence Pre-training for Natural Language Generation, Translation, and Comprehension

■ Date	@February 24, 2025
■ Description	Bert의 encoder와 gpt-2의 decoder를 결합해 BART라는 모델을 제안함과 동시에 data에 다양한 변형을 가해줘 generalization 성능을 올려 보다 다양한 task에 적용할 수 있도록 함
■ Keyword	Architecture
■ Status	Done
■ URL	https://arxiv.org/pdf/1910.13461

Overview

BART is denoising autoencoder for pretraining sequence-to-sequence models.

- BART is effective when fine tuned for text generation but also works well for comprehension tasks.
- BART의 구조
- BART의 성능 향상 방법과 실험 결과

Introduction

마스킹된 토큰의 분포, 마스킹된 토큰을 예측하는 순서와 마스킹된 토큰을 교체하기 위해 사용할 수 있는 컨텍스트 개선을 통해 성능 향상을 이룬 기존 모델들은 특정 task에 집중되어 있어

applicability가 떨어진다.

Bidirectional transformer와 Auto-Regressive Transformer를 결합한 모델 ⇒ BART

BART는...

- Denoising Autoencoder로 sequence-to-sequence model로 구축되었고 다양한 task에 적용이 가능

BART의 Pretraining stages

1. Text가 임의의 Noising function으로 변형
2. Sequence-to-Sequence model은 원본 text를 복원하도록 학습

주요 장점

- Noising flexibility

Original text에 길이 변환을 포함한 임의의 변환이 가능

기존 문장의 순서를 임의로 섞은 것과 novel-in-filling scheme(text의 일부분이 single mask token으로 채워짐)에서 모두 최고의 성능을 내는 방법을 찾았다.

→ 이러한 접근 방식은 BERT에서 original word masking과 next sentence prediction objectives를 일반화해 모델이 전체 문장의 길이를 더 추론하게하고 입력에 긴 범위의 변형을 만들도록 한다.


BART를 추가적인 transformer layer 위에 쌓음으로서 machine translation의 새로운 방식을 제안한다.

▼ Related work

Encoder + Decoder vs Decoder

ELMo: Shallow bidirectional → Deep bidirectional


BERT



- Random tokens는 mask로 대체
- document는 양방향으로 encode


→ 비어있는 token들은 독립적으로 예측되므로 generation에 사용되기 어려움

GPT



- token들은 atuo-regressively하게 예측
 - 왼쪽 context만을 가지고 생성
- 양방향 interaction을 학습할 수 없음

BART



- Encoder의 입력과 Decoder의 출력이 반드시 정렬되어 있을 필요가 없음
- 변형된 document는 Bidirectional model로 encode
- Autoregressive Decoder로 원본 document와 유사한 document가 생성
- Fine-tuning의 경우, 변형되지 않은 document가 encoder와 decoder 모두의 입력으로 들어가고 decoder의 마지막 hidden state의 representation을 사용

Model

BART는 denoising autoencoder로 변형된 document를 원본 document로 매칭하는 작업을 수행한다. sequence-to-sequence model의 형태이고 bidirectional encoder와 left-to-right autoregressive decoder로 이루어져있다. Pre-training에선 원본 document의 negative log likelihood를 optimize한다.

Architecture

Initialise parameter from $N(0, 0.02)$, use 6 layers in the encoder and decoder and for large model use 12 layers in each.


BERT에 사용된 architecture와 유사하지만 차이점이 있다.

1. Decoder의 각 layer는 encoder의 마지막 hidden layer와 cross-attention
2. BERT는 word-prediction 전에 feed-forward network가 존재하지만 BART에는 존재하지 않음

Pre-training BART

Decoder의 output과 original document 사이의 cross-entropy를 계산


- 어떤 종류의 document 손상이던 사용 가능



- Token Masking
- Token Deletion
- Text Infilling
- Sentence Permutation
- Document Rotation

Fine-tuning BART

- Sequence Classification Tasks




- Encoder와 Decoder에 같은 입력
- 마지막 decoder의 마지막 hidden state를 새로운 multi-class linear classifier의 입력으로 사용
- BERT의 CLS 토큰과의 비교

BERT에서는 CLS 토큰이 문장의 시작에 추가되어 이 토큰의 최종 임베딩을 문장 전체의 대표 벡터로 활용 → bidirectional하기 때문에

BART는 추가적인 토큰을 문장의 끝에 배치해 전체 입력과 디코더의 모든 상태를 담도록 함 →

pre-training을 통해 start token에 언어의 정보(기본적인 개념)가 담긴다.
- Token Classification Tasks
 - Encoder와 Decoder에 완전한 document를 입력으로 넣어주고 decoder의 최상위 hidden state를 각 단어의 representation으로 사용
 - Representation은 token을 구별하는데 사용
 - 이러한 representation을 classifier에 입력으로 넣어줘 classification task를 수행
- Sequence Generation Tasks
 - Autoregressive decoder를 가지기 때문에 fine tune을 통해 sequence generation task에 사용될 수 있음
 - Information은 입력으로부터 복사되지만 변형되어 사용
 - Encoder의 입력은 input sequence이고 decoder는 output을 autoregressive하게 생성

- Machine Translation



- 기계번역을 위해 BERT 모델 전체를 하나의 pretrained decoder로 사용
BART의 word embedding을 새로운 추가적인 encoder로 대체
추가적인 encoder는 BART와 완전히 다른 어휘도 사용 가능
- 1. BART 파라미터의 대부분을 고정하고 새로운 encoder, BART positional embeddings, BART's encoder 첫번째 layer의 self-attention input projection matrix를 update
⇒ 새로운 encoder가 외국어를 BART가 이해할 수 있는 형태(영어)로 변환하는 방법을 학습
- 2. 적은 Iteration으로 모델 파라미터 전체를 훈련

Comparing Pre-training Objectives

Comparison Objectives

- Language Model: GPT와 같은 left-to-right을 예측하는 모델
- Permuted Language Model: XLNet 기반 모델로, 순서를 무작위로 섞은 후 원래 단어를 예측

- Masked Language Model: BERT와 동일한 방식으로 학습 → mask 토큰을 예측
- Multitask Masked Language Model: Masked Language Model을 추가적인 self-attention mask를 통해 학습
- Masked Seq-to-Seq: 문장의 일부 구간을 가리고 encoder - decoder model로 학습

1. 기본 sequence-to-sequence 문제로 다루기

encoder source input과 decoder output을 명확히 구분해 학습하는 방법

→ BART 모델에서 잘 작동

2. decoder의 target 앞에 source를 붙이는 방법: Decoder input = Source + Target

손실 함수를 타겟 부분에서만 적용하는 방법

→ BART 이외의 모델에서 잘 작동

Tasks

- SQuAD(Stanford Question Answering Dataset): MRC(Machine Reading Comprehension)을 평가하기 위한 대표적 데이터 셋
- MNLI: 두문장의 연관성을 확인하는 데이터
- ELI5(Long-form Abstractive Questioning Answering Dataset): 질문과 주어진 documents를 통해 답변을 생성
- XSum: 뉴스 요약
- ConvAI2: XSUM보다 extractive 성능이 강한 데이터
- CNN/DM: 자연스러운 대화 응답 생성

Results

- Performance of pre-training methods varies significantly across tasks
Pre-training methods의 effectiveness는 task에 매우 의존적이다.
- Token masking is crucial
 - 낮은 성능: Rotating document나 permuting sentences (단독으로)
 - 높은 성능: Token deletion, token masking, self-attention mask
 Generation task의 경우 deletion이 masking보다 성능이 좋게 나타났다.

- **Left-to-right pre-training improves generation**

유일하게 pre-training 과정에서 left-to-right auto-regressive language modeling을 포함하지 않은 Masked Language Model과 Permuted Language Model은 다른 모델들에 비해 generation에서 낮은 성능을 보였다.

- Bidirectional encoders are crucial for SQuAD

left-to-right decoder는 SQuAD에서 낮은 성능을 보인다.

→ Classification decisions에서 future context는 중요!

BART는 (BERT보다) 절반 정도의 bidirectional layer를 가지고 비슷한 성능을 보였다.

- The pre-training objective is not the only important factor

Permuted Language Model이 XLNet보다 낮은 성능을 보인 이유는 다른 architectural improvements(relative-position embeddings, segment-level recurrence)를 포함하지 않기 때문이다.

- Pure language models perform best on ELI5

다른 모델이 BART보다 좋은 성능을 보이는 유일한 Generation task

→ Output이 input과 거리가 멀수록 BART는 안 좋은 성능을 보인다.

- **BART achieves the most consistently strong performance**

BART with text-infilling은 ELI5를 제외한 모든 task에서 좋은 성능을 보였다.

Large-scale Pre-training Experiments

Downstream performance의 경우 pre-training이 배치 수에 따라 크게 개선될 수 있다.

- Discriminative Tasks

BART는 대부분의 task에서 다른 모델들과 비슷한 성능을 냈다.

→ Generation task에서 BART의 성능 향상은 classification performance 성능 저하를 수반하지 않는다.

- Generation Tasks

Fine-tuning 시에 label smoothed cross entropy loss를 사용한다.

→ Conversational response generation에서 BART가 가장 좋은 성능을 보였다.

- Summarization

- CNN/DailyMail: resemble source sentences → Extractive models
BART가 기존의 모델들보다 좋은 성능을 보였다.
- XSum: Highly abstractive
기존의 최상의 모델보다 BART가 좋은 성능을 보였다.
- Dialogue
 - CONVAI2: 응답을 previous context와 textually-specified persona에 모두 기반하여 생성
BART 두개의 automated metric에서 기존의 모델보다 좋은 성능을 보였다.
- Abstractive QA
 - ELI5
BART가 기존의 최상의 모델보다 더 좋은 성능을 보였다.
- Translation
WMT16 Romanian-English + back-translation data
back-translation data가 없을 경우 BART는 덜 효과적이고 overfitting에 취약하다.

Qualitative Analysis

BART는 Summarization에서 큰 성능 향상을 보여준다.

- WikiNews article
 - fluent and grammatical English
 - factually accurate
 - integrates supporting evidence (from across the input document with background knowledge)
 - highly abstractive(input에서 복사된 문장들)

⇒ BART pretraining은 natural language understanding과 generation의 강한 결합을 학습한다!

Summary

- BART는 Denoising Autoencoder처럼 원본 document를 변형하고, 이를 원본 문장으로 복원하는 방식으로 학습한다.
- BART는 pre-training 과정에서 왼쪽과 오른쪽 context words 사이의 상호작용을 가능하게하고 다양한 노이즈 변형을 추가한 Masked language modelling을 제안했다.
- BART는 encoder-decoder(sequence-to-sequence) 구조를 사용하며, encoder는 Bidirectional하고 decoder는 Auto-Regressive하게 작동한다.