

Generative Adversarial Networks

📅 Date	@March 25, 2025
🔑 Keyword	Discriminative Model GAN Generative Model
⚙️ Status	Done
🔗 URL	https://arxiv.org/abs/1406.2661

Overview

Adversarial process를 통해 Generative model을 추정하는 새로운 framework를 제안한다.

이 framework는 두개의 model로 이루어져있다.

1. Generative model G

Data 분포를 capture

D가 실수할 확률을 최대로 만드는 것이 목표이다.

2. Discriminative model D

주어진 샘플이 실제 훈련 데이터에서 왔을(혹은 G가 생성한 데이터) 확률을 예측하는 모델

임의의 함수 공간에서의 G와 D에 대해, 유일한 해가 존재한다.

→ G가 훈련 데이터의 분포를 완전히 복원하고 D는 모든 입력에 대해 1/2의 값을 갖는다.

G와 D는 모두 multilayer perceptron이므로 backpropagation을 통해 훈련될 수 있다.

Introduction

대부분의 성공적인 deep learning model들은 discriminative model을 포함한다.

기존의 Generative model들의 학습방식은 MLE(Maximum Likelihood Estimation)은 계산이 어려운 확률 계산들을 근사하기 어렵고 piecewise linear units(ReLU, Leaky ReLU)의 장점을 충분히 활용하기 어렵 (backpropagation 과정에서의 비미분성, 표현력 부족 등).

→ 이러한 문제점을 극복하는 Generative model estimation의 과정을 제시

Adversarial Net(적대적 신경망)에서는 Generative model이 Adversary model과 대결한다.

Adversarial Net에서 Generative model은 multilayer perceptron으로 랜덤 noise를 전송하고 Discriminative model도 multilayer perceptron을 사용한다.

→ 이러한 방법을 통해 우리는 두 모델 모두 backpropagation과 dropout algorithm만을 사용해 훈련할 수 있다. 그리고 Generative model에서 sample을 얻을 때는 forward propagation을 통해 얻는다.

▼ Related work

Directed Graphical Models with latent variables의 대안인 Undirected graphical models with latent variables → Restricted Boltzmann machines (RBMs), deep Boltzmann machines (DBMs)

Deep belief network (DBNs)는 하나의 undirected layer와 여러개의 directed layer를 포함하는 하이브리드 모델이다.

Denoising auto-encoder나 contractive autoencoder등의 모델의 학습 규칙은 RBMs에 적용된 score matching과 비슷하다.

NCE는 별도의 Discriminative model을 사용하지 않고, Generative model이 생성된 data를 스스로 구분하도록 한다.

Probability distribution을 명시적으로 정의하지 않는 모델들은 generative stochastic network (GSN, parameterized Markov chain을 정의)을 반드시 포함한다.

→ Adversarial net은 생성 시에 feedback loop를 요구하지 않으므로(Markov chain 또한 필요하지 않다.) piecewise linear units를 활용하기 더 좋다.

- Backpropagation 성능을 향상시킨다.
- Unbounded activation으로 인한 문제가 feedback loop시에 발생한다.

Adversarial nets

두개의 모델이 모두 multilayer perceptron일 때 adversarial modeling framework를 적용하기 수월하다.

우리는 D를 training example과 G에서 도출된 sample 모두에 있어서 정확한 label에 대한 확률을 최대화하도록 학습한다.

G는 $\log(1 - D(G(z)))$ 를 최소화하도록 학습한다.

→ D와 G는 $V(G, D)$ 를 가지고 two-player minimax game을 하는 것이다.

GAN의 training criterion이 충분한 표현력을 가진 G와 D가 주어진다면, Data Generating Distribution을 복원한다는 것을 분석한다.

학습 과정의 내부 loop에서 D를 완전히 최적화시키는 것은 계산적으로 비효율적이고 overfitting을 불러올 수 있다. → G를 학습시키기 위해 매 스텝마다 D를 완전히 최적화시키는 것

→ 우리는 k step 동안 D를 최적화시키고 1 step 동안 G를 최적화시킨다.

이렇게하면 D는 optimal solution에 가깝게 유지되고 G는 천천히 변형된다.

그리고 G가 $\log(1 - D(G(z)))$ 를 최소화하도록 학습하는 대신에 G가 $\log(D(G(z)))$ 를 최대화하도록 학습한다.

Theoretical Results

Global Optimality of $p_g = p_{data}$

최적의 D

$$D_G^*(x) = \frac{p_{data}(x)}{p_{data}(x) + p_g(x)}$$

Theorem 1. The global minimum of the virtual training criterion $C(G)$ is achieved if and only if $p_g = p_{data}$. At that point, $C(G)$ achieves the value $-\log 4$.

Convergence of Algorithm 1

Proposition 2. If G and D have enough capacity, and at each step of Algorithm 1, the discriminator is allowed to reach its optimum given G, and p_g is updated so as to improve the criterion $E_{x \sim p_{data}}[\log D_G^*(x)] + E_{x \sim p_g}[\log(1 - D_G^*(x))]$ then p_g converges to p_{data}

⇒ 실제로 Adversarial net은 p_g 의 분포 중 제한적인 부분만 표현한다. 이론적으로 증명이 부족하더라도 MLP가 실전에선 꽤 잘 작동하기 때문에 잘 사용한다.

Experiment

Model	MNIST	TFD
DBN [3]	138 ± 2	1909 ± 66
Stacked CAE [3]	121 ± 1.6	2110 ± 50
Deep GSN [6]	214 ± 1.1	1890 ± 29
Adversarial nets	225 ± 2	2057 ± 26

Table 1: Parzen window-based log-likelihood estimates. The reported numbers on MNIST are the mean log-likelihood of samples on test set, with the standard error of the mean computed across examples. On TFD, we computed the standard error across folds of the dataset, with a different σ chosen using the validation set of each fold. On TFD, σ was cross validated on each fold and mean log-likelihood on each fold were computed. For MNIST we compare against other models of the real-valued (rather than binary) version of dataset.




Figure 2: Visualization of samples from the model. Rightmost column shows the nearest training example of the neighboring sample, in order to demonstrate that the model has not memorized the training set. Samples are fair random draws, not cherry-picked. Unlike most other visualizations of deep generative models, these images show actual samples from the model distributions, not conditional means given samples of hidden units. Moreover, these samples are uncorrelated because the sampling process does not depend on Markov chain mixing. a) MNIST b) TFD c) CIFAR-10 (fully connected model) d) CIFAR-10 (convolutional discriminator and “deconvolutional” generator)

- Generator에서 생성된 샘플이 얼마나 실제 데이터 분포를 잘 근사하는지 간접적으로 평가하기 위해 log-likelihood를 사용한다. → GAN generator의 샘플을 평가
Gaussian의 sigma는 validation set의 cross validation에 의해 구해졌다.
- Generator가 만들어낸 샘플을 기존 방법들이 만들어낸 샘플들에 비해 우월하진 않지만 비슷한 성능을 보인다. → GAN의 성장 가능성

Advantages and disadvantages

장점

- Markov chain이 필요하지 않고 backprop만을 통해 훈련이 가능하다는 것이다 → 매우 다양한 함수가 model 안에서 작동할 수 있다.
- Adversarial model은 generator network가 data example을 통해 직접 update가 되지 않고 D를 통해 간접적으로 update된다는 점에서 statistical 장점을 가진다
→ Overfitting 방지 가능
- 뚜렷하고 선명한 분포를 잘 학습할 수 있다.
이에 반해 Markov Chain은 mixing을 위해 흐릿한 분포가 필요하다.

단점

- 명시적인 확률 밀도 함수의 부재 → $p_g(x)$ 에 대한 명시적인 표현이 없어 정량적으로 평가할 때 어려움이 발생한다.
- Generator와 Discriminator의 동기화의 필요성 → 각 모델 업데이트를 동기화해야 한다.

Summary

- Generator와 Discriminator를 동시에 학습시키는 적대적 구조를 제안한다.
- Generator는 노이즈를 받아 데이터를 생성하고, Discriminator는 진짜/가짜를 구별하도록 학습된다
- GAN은 확률 분포를 명시적으로 모델링하지 않고, 암묵적으로 학습하여 복잡한 likelihood 계산을 피한다.

- 학습은 오직 backpropagation만으로 가능하며, Markov chain이나 복잡한 샘플링 없이 훈련된다.
- GAN은 선명하고 고품질의 샘플 생성이 가능하며, 기존 샘플링 기반 모델보다 표현력이 우수하다.