

Segment Anything

📅 Date	@September 29, 2025
≡ Key contribution	Segment Anything project에서는 image segmentation의 새로운 task, promptable segmentation, SAM(Segment Anything Model), SA-1B dataset을 제안해 image segmentation의 새로운 foundation model을 만들려했으나, segmentation이라는 한정적인 scope 때문에 진짜 foundation model인지는 의문이다.
≡ Keyword	Segment Anything Model Segmentation zer-shot transfer
⚙ Status	Done
🔗 URL	https://arxiv.org/abs/2304.02643

Overview

Segment Anything project: Image segmentation에 새로운 task, model, dataset을 제안한다.

- 11M개의 이미지에 대해 1 billion개의 마스크를 가지는 가장 큰 segmentation dataset을 만들고
- Model은 promptable하게 훈련되어 zero-shot으로도 새로운 image domain에 대해 적용이 가능하도록 한다.

Introduction

LLM은 web-scale dataset에 대해 pre-train되어 매우 강한 zero-shot, few-shot 성능에 도달했다.

Prompt engineering을 통해 이러한 우수한 foundation model이 생겨났고 fine-tuned model만큼의 성능을 도달했다.

Computer vision 분야에서도 CLIP과 ALIGN과 같은 foundation model들이 개발되었다.

이를 바탕으로 본 연구에서는 image segmentation에 대한 foundation model을 만드는 것이 목표다.

- Promptable model
- 강한 일반화가 될 수 있는 거대 dataset을 사용해 pre-train
- 여러 downstream segmentation problem들을 해결하는 것이 목표

Task

Promptable segmentation task: segmentation prompt가 주어졌을 때 유효한 segmentation mask를 반환하도록 하는 것이 목표

Prompt는 간단하게 어떤 걸 segment 한 건지에 대한 정보로 spatial 이나 text information을 포함한다. 여기서 유효한 output mask란 prompt가 모호하고 여러개의 객체를 지칭할지라도 output은 적어도 하나의 객체에 대한 타당한 mask를 말한다.

Model

간단한 디자인이 아래 3가지를 만족시킨다.

- Image encoder가 image embedding을 계산
- Prompt encoder가 prompt를 embedding
- 두개의 정보가 mask decoder에 의해서 통합되고 segmentation mask를 도출

이러한 모델을 Segment Anything Model(SAM)이라고 부른다.

Data Engine

새로운 데이터에 대해 모델을 일반화시키기 위해서는 SAM을 크고 다양한 mask에 대해서 학습시켜야 한다. 우리는 data engine을 만들어 SAM을 훈련시킨다.

Dataset

위에 과정으로 만들어진 최종 dataset SA-1B는, 11M개의 이미지에 대해 1B개의 mask를 가지고 있다. → 다른 segmentation dataset보다 400배 이상 많은 데이터를 가짐

Responsible AI

이 데이터셋은 지리적으로나 경제적으로 다양한 나라에 분포되어 있어 실제 세계를 잘 표현한다.

Experiments

- 하나의 foreground point에 대해 높은 퀄리티의 mask를 생산한다.
- 여러 downstream task에 대해, prompt engineering을 통한 zero-shot transfer에서 좋은 성능을 보인다.

SAM은 prompt engineering을 통해 여러 task에 대해 사용될 수 있을 것이다.

Methods: Segment Anything Task



Figure 3: Each column shows 3 valid masks generated by SAM from a single ambiguous point prompt (green circle).

Promptable segmentation task란 모든 prompt에 대해 유효한 mask를 출력하도록 하는 task이다. → 이 NLP에서의 방식과 유사하다.

이러한 task는 자연스러운 pre-training algorithm과 zero-shot transfer를 가능하게 한다.

Pre-training

Natural pre-training algorithm: 각 sample마다 prompt(points, boxes, masks)를 주고 model의 mask prediction과 gt를 비교하는 과정

우리의 목적은 모호한 prompt에 대해서도 유효한 mask를 출력할 수 있도록 하는 것이다.

Zero-shot transfer

Downstream task는 적절한 prompt를 통해 간단하게 해결될 수 있다.

예를 들어 cat bounding box detector와 결합해 cat을 segmentation하도록 할 수 있다.

Related task

Segmentation에는 다양한 종류의 task가 존재: interactive segmentation, edge detection, super pixelization, object proposal generation, foreground segmentation, semantic segmentation, instance segmentation, panoptic segmentation 등

우리 모델의 핵심 차별점은 큰 system의 component로 새로운 task에 대해서도 수행이 가능하다는 점이다.

예를 들어 object detector와 결합해 instance segmentation을 수행한다.

Discussion

이러한 결합가능한 system design은 여러 다양한 task에 대해 적용이 가능하다.

Method: Segment Anything Model




Figure 4: Segment Anything Model (SAM) overview. A heavyweight image encoder outputs an image embedding that can then be efficiently queried by a variety of input prompts to produce object masks at amortized real-time speed. For ambiguous prompts corresponding to more than one object, SAM can output multiple valid masks and associated confidence scores.

SAM은 image encoder, prompt encoder, mask decoder 총 3개의 component를 가진다.

Image Encoder

MAE pre-trained Vision Transformer를 사용한다.

Prompt Encoder

두 종류의 prompt를 사용: sparse(point, box, text)와 dense(mask)

Point와 box는 positional encoding과 learned embedding의 합으로 나타내어지고 free-form text는 CLIP을 사용한다.

Dense prompt에 대해서는 convolution으로 embedding되고, image embedding과 함께 element-wise sum된다.

Mask Decoder

image embedding, prompt embedding, output token을 mask에 매핑시킨다.

구조는 Transformer의 decoder bloxk과 dynamic mask prediction head로 이루어져있고, prompt self-attention과 cross-attention을 두 방향으로 사용해 모든 embedding을 업데이트한다. → prompt-to-image와 image-to-prompt

이후 image embedding을 upsample하고 MLP는 output token을 dynamic linear classifier에 매핑한다. 이 classifier는 최종적으로 각 이미지 위치에서 마스크가 foreground일 확률을 예측한다.

Efficiency

미리 image embedding이 계산되고, prompt encoder와 mask decoder는 web browser에서 최대 50ms로 작동한다.

Losses and training

focal loss와 dice loss의 합으로 평가한다.

Method: Segment Anything Data Engine

3단계를 가진다.

Assisted-manual stage

Professional annitator들은 직접 foreground와 background를 클릭해서 label을 생성한다.

SAM은 처음에 public segmentation dataset을 사용해 훈련되고, 충분한 양의 data가 annotation되면, 새롭게 annotation된 mask에 대해서 재훈련된다.

Semi-automatic stage

mask의 다양성을 높이고자 annotator들은 덜 중요한 객체에 대해 annotation하도록 한다.

먼저 자동적으로 confident mask를 감지하고, 이러한 mask를 가지고 있는 image를 annotator들에게 제공해 추가적인 객체들을 찾도록 한다.

⇒ Average annotation time은 증가했고, average number of masks per image도 44에서 72로 증가했다.

Fully automatic stage

마지막 단계에서 annotation은 모두 automatic하게 부여된다. → 모든 11M개의 이미지에 automatic mask generation을 적용한다.

Method: Segment Anything Dataset




Figure 5: Image-size normalized mask center distributions.




Figure 6: Dataset mask properties. The legend references the number of images and masks in each dataset. Note, that SA-1B has $11\times$ more images and $400\times$ more masks than the largest existing segmentation dataset Open Images [60].

Images

Photographer들에게 제공받은 high-resolution image($3300 * 4950$)를 사용하는데 downsampling해 사용한다. downsampling되어도 다른 image data보다는 높은 해상도를 가진다.

Masks

자동 생성된 mask와 professional annotation을 비교해봤을 때, 자동 생성된 mask가 high quality이고 모델 훈련에 더 효율적이다.

Mask quality

랜덤하게 샘플링된 500개의 이미지에 대해 professional annotator들에게 물어봤을 때, 자동 마스크에 대한 모델 학습이 data engine을 통해 나온 마스크에 대한 학습만큼 좋다.

Mask properties

1. SA-1B가 LVIS v1이나 ADE20K보다 image corner를 잘 커버하고 있다.
2. SA-1B가 두번째로 큰 dataset인 Open Image보다 11배 더 많은 이미지를 가지고 400배 더 많은 mask를 가진다.
3. SA-1B가 더 많은 작거나 중간 크기인 mask를 가지고 있다.
4. 형태 복잡성(concavity분포)은 다른 데이터셋과 유사하다.

Experiments: Zero-Shot Transfer Experiments

Zero-Shot Single Point Valid Mask Evaluation




Figure 9: Point to mask evaluation on 23 datasets. (a) Mean IoU of SAM and the strongest single point segmenter, RITM [92]. Due to ambiguity, a single mask may not match ground truth; circles show “oracle” results of the most relevant of SAM’s 3 predictions. (b) Per-dataset comparison of mask quality ratings by annotators from 1 (worst) to 10 (best). All methods use the ground truth mask center as the prompt. (c, d) mIoU with varying number of points. SAM significantly outperforms prior interactive segmenters with 1 point and is on par with more points. Low absolute mIoU at 1 point is the result of ambiguity.

Task

하나의 foreground point에 대해 segment하는 성능을 평가한다.

Datasets

다양한 image distribution을 가지는 23 dataset을 사용한다.

Results

1. 23 dataset중에 16개에서 SAM이 높은 결과를 보였고, oracle(상위 3개의 mask를 선택해 gt와 비교) 성능도 비교해보았을 때 SAM이 RITM보다 모든 dataset에

서 높은 성능을 보였다.

2. Annotator들이 SAM의 mask quality를 높게 평가했고 이는 SAM이 하나에 포인트에 대해 유효한 마스크를 segment하는 법을 학습했다고 볼 수 있다.
3. 다른 Baseline들과 비교를 했을 때 성능차이가 에포크가 늘어날수록 줄어드는데 이는 task가 쉬워지기 때문이라고 해석할 수 있다.
4. center point를 샘플링하지 않고, random point를 샘플링 했을 때도 SAM이 더 좋은 성능을 보였다.

Zero-Shot Edge Detection




Figure 10: Zero-shot edge prediction on BSDS500. SAM was not trained to predict edge maps nor did it have access to BSDS images or annotations during training.

SAM은 edge detection에 대해 훈련되지 않더라도 좋은 성능을 보였고 gt와 비교했을 때, 더 자세한 edge까지 detection할 수 있었다.

Zero-Shot Object Proposals

method	mask AR@1000						
	all	small	med.	large	freq.	com.	rare
ViTDet-H [62]	63.0	51.7	80.8	87.0	63.1	63.3	58.3
<i>zero-shot transfer methods:</i>							
SAM – single out.	54.9	42.8	76.7	74.4	54.7	59.8	62.0
SAM	59.3	45.5	81.6	86.9	59.1	63.9	65.8

Table 4: Object proposal generation on LVIS v1. SAM is applied zero-shot, *i.e.* it was not trained for object proposal generation nor did it access LVIS images or annotations.

SAM은 medium, large 객체와 rare, comon 객체에 대해 ViTDet-H보다 좋은 성능을 보인다.

Zero-Shot Instance Segmentation




Figure 11: Mask quality rating distribution from our human study for ViTDet and SAM, both applied to LVIS ground truth boxes. We also report LVIS and COCO ground truth quality. The legend shows rating means and 95% confidence intervals. Despite its lower AP (Table 5), SAM has higher ratings than ViTDet, suggesting that ViTDet exploits biases in the COCO and LVIS training data.

AP는 ViTDet가 더 높게 나왔지만
annotator에게 mask의 퀄리티를 평가하
라고 했을 때 SAM이 ViTDet를 능가했다.

Zero-Shot Text-to-Mask

훈련 중에 추출된 CLIP 이미지 임베딩으로 SAM에 프롬프트를 제공하고, CLIP이 image embedding과 text embedding이 매칭되도록 훈련되었기 때문에 추론에는 text embedding을 사용할 수 있다.




Figure 12: Zero-shot text-to-mask. SAM can work with simple and nuanced text prompts. When SAM fails to make a correct prediction, an additional point prompt can help.

간단한 text prompt에 대해서
segmentation을 수행할 수 있다.

Ablations




Figure 13: Ablation studies of our data engine stages, image encoder scaling, and training data scaling. (Left) Each data engine stage leads to improvements on our 23 dataset suite, and training with only the automatic data (our default) yields similar results to using data from all three stages. (Middle) SAM trained with $\sim 10\%$ of SA-1B and full SA-1B is comparable. We train with all 11M images by default, but using 1M images is a reasonable practical setting. (Right) Scaling SAM's image encoder shows meaningful, yet saturating gains. Nevertheless, smaller image encoders may be preferred in certain settings.

- Data engine의 각 단계의 데이터로 훈련했을 때 segmentation 결과
4번째 step으로 automatic mask만 사용한 경우를 추가했을 때, 각 stage가 지날수록 mIoU가 증가한다.
- Data volume을 늘려가며 비교
full SA-1B는 11M개의 image를 가지고, 1M개와 0.1M개를 샘플링해서 실험했을 때 0.1M개의 이미지를 사용했을 때 눈에 띄는 하락이 있었고, 100M개의 mask는 필요하다.
- ViT-B와 ViT-L, ViT-H를 image encoder로 사용해 비교
image encoder scale은 성능과 크게 연관성있지 않다.

Discussion

Foundation models

Foundation model이란 넓고 다양한 데이터에 대해 학습되어 여러 downstream task에 적용할 수 있는 모델

SAM도 foundation model에 부합하지만, segmentation은 일부 제한된 scope라는 한계점이 존재한다.

대규모 학습 데이터 supervised 학습 덕분에 효과적인 훈련을 진행해 높은 generalizability를 가지는 model이 탄생했다.

Compositionality

Pre-trained된 SAM은 새로운 task에 대해 다른 시스템과 결합해 적용될 수 있다.
SAM의 generalizability 때문에 새로운 환경에 잘 적응한다는 것이 장점이다.

Limitations

SAM의 성능은 작은 물체나 분리된 물체의 경우 잘 작동하지 않음

- image encoder에 따라 실시간 성능이 결정
- text-to-mask는 아직 불완전
- Prompt 설계가 중요
- 도메인 특화 작업에 취약

Summary

Segment Anything은 foundation model로서의 이미지 segmentation 통합을 시도했고

1. 새로운 task: Promptable segmentation
2. SAM 모델
3. 대규모 데이터셋 (SA-1B)

를 제안했다.