

An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale

■ Date	@September 18, 2025
■ Keyword	Attention-based model Pre-training Transfer learning Transformer image view synthesis
■ Status	In progress
■ URL	https://arxiv.org/abs/2010.11929

Overview

- 이미지를 고정 크기의 패치 시퀀스로 분할하여 NLP의 토큰처럼 표준 Transformer encoder에 직접 입력으로 사용하는 Vision Transformer(ViT) 모델을 제안한다.
- 기존 CNN과 달리 이미지 특유의 inductive bias 편향을 최소화한 VT는 대규모 데이터셋에서 Pretrain될 때 뛰어난 성능을 보인다.
- ViT는 여러 이미지 인식 benchmark에서 최첨단 CNN보다 더 좋은 성능을 보이고 학습에 훨씬 더 적은 연산 자원을 요구하므로 매우 효율적이다.

Introduction

배경

- Self-attention에 기반한 모델인 Transformer는 NLP에서 매우 잘 활용되었다. → 매우 큰 text 데이터에 대해서 pretrain되고, 작은 task-specific dataset에서 fine-tune되는 방식을 사용
- Computer vision에서는 convolutional architecture가 주를 이뤘다.
이후 self-attention과 CNN을 섞으려는 시도들이 계속 있었다.

아이디어

Transformer에 최대한 적은 모델 변형을 주며 image를 바로 입력으로 사용하는 방법에 대해 실험을 진행했다.

- Transformer의 입력으로 image를 patch로 나눈 뒤 linear embedding을 적용한 것을 사용한다.

Image의 patch = NLP에서의 token(word)

성능의 차별점

적은 개수의 data에 대해서 training되었을 때는 ResNet보다 좋지 못한 성능을 보이는데 이는 "Transformers lack some of the inductive biases inherent to CNNs, such as translational equivariance and locality, and therefore do not generalize well when trained on insufficient amounts of data" 의 영향으로 보여진다.

Image 데이터가 가지는 기본적인 특징들(주변 픽셀들간의 연관관계, 위치와 객체간의 연관성)을 transformer는 구조적으로 가지고 있지 않다!

하지만, 매우 큰 dataset에서 train되었을 경우, 대규모 학습 >>> inductive bias임이 밝혀졌다.

NLP에서의 Transformer처럼, 매우 큰 데이터에 대해서 pre-train되고, 적은 data를 가지는 task에 대해서 전이되었을 때 매우 좋은 성능을 보인다.

▼ Related Work

Transformer가 NLP task들의 SOTA를 달성하고 있다. 이후 BERT나 GPT같은 파생모델들이 많이 생겨났다.

Self-attention을 image에 적용할 때, 각 픽셀은 다른 모든 픽셀들과의 연관성을 파악해야 한다. 하지만 pixel 수가 매우 많아지면 연산 비용이 기하급수적으로 증가하기 때문에 현실적으로 불가능하다. 이를 위해 여러 approximation 기법들이 시도되었다. 또한, CNN과 self-attention을 혼합하려는 시도도 많이 있었다.

한계점: 이러한 특수화된 attention architecture는 computer vision task에서 유의미한 결과를 보였지만, hardware accelerator에서 구현하기 위해서는 복잡한 engineering 기술이 필요하다.

ViT와 유사한 방법이 이전에 존재했지만, 우리의 연구는 large scale pre-training의 중요성을 조금 더 강조한다.

Methods




Figure 1: Model overview. We split an image into fixed-size patches, linearly embed each of them, add position embeddings, and feed the resulting sequence of vectors to a standard Transformer encoder. In order to perform classification, we use the standard approach of adding an extra learnable “classification token” to the sequence. The illustration of the Transformer encoder was inspired by Vaswani et al. (2017).

$$\mathbf{z}_0 = [\mathbf{x}_{\text{class}}; \mathbf{x}_p^1 \mathbf{E}; \mathbf{x}_p^2 \mathbf{E}; \dots; \mathbf{x}_p^N \mathbf{E}] + \mathbf{E}_{\text{pos}}, \quad \mathbf{E} \in \mathbb{R}^{(P^2 \cdot C) \times D}, \mathbf{E}_{\text{pos}} \in \mathbb{R}^{(N+1) \times D} \quad (1)$$

$$\mathbf{z}'_\ell = \text{MSA}(\text{LN}(\mathbf{z}_{\ell-1})) + \mathbf{z}_{\ell-1}, \quad \ell = 1 \dots L \quad (2)$$

$$\mathbf{z}_\ell = \text{MLP}(\text{LN}(\mathbf{z}'_\ell)) + \mathbf{z}'_\ell, \quad \ell = 1 \dots L \quad (3)$$

$$\mathbf{y} = \text{LN}(\mathbf{z}_L^0) \quad (4)$$

Input

기존의 Transformer는 1D sequence of token embedding을 입력으로 사용한다.

$H \times W \times C$ 의 image를 $\rightarrow$ 하나의 patch 당 $N \times (P^2 \cdot C)$ 인 patch들의 sequence로 변형하여 사용

Transformer는 사이즈 D의 latent vectore를 모든 레이어에서 사용하기 때문에 flatten 된 patch들을 D dimension으로 훈련 가능한 linear projection을 통해 매핑한다.

BERT의 [class] 토큰과 유사한 class 토큰

임베딩된 patch sequence의 앞에 학습 가능한 class token을 추가해 이 class token의 결과값을 이미지 전체의 representation으로 사용한다.

이후 pre-training과 fine-tuning 시에 classification head의 입력으로 사용된다.

Position embedding

patch embedding에 position embedding을 더해줘 위치 정보를 가질 수 있도록 한다.

- Standard learnable 1D position embedding을 사용

Inductive bias

CNN에 비해 Transformer는 이미지에 특화된 inductive bias를 가지지 않는다.

- locality, two-dimensional neighborhood structure, translation equivariance가 CNN이 구조적으로 가지고 있는 편향이다.
- ViT에서는 image를 patch로 자르는 부분과 position embedding을 fine-tuning 시에 조절하는 부분 말고 position embedding은 patch의 2D position에 대한 정보를 하나도 가지지 않는다. → 모두 ViT가 스스로 학습을 해야함

Hybrid Architecture

image의 pixel을 그대로 사용하는 것 대신에 CNN에서 나온 feature map을 통해 input sequence를 생성해서 transformer의 입력으로 사용하는 방법이다.

Fine-tuning and higher resolution

우리는 ViT를 매우 큰 dataset에 대해서 pre-train하고, downstream task에 대해 fine-tune하는 과정을 거친다.

방법: Pre-train한 prediction head를 대신 0으로 초기화된 $D \times K$ (K =downstream task class의 개수)의 feed forward network를 추가한다.

Pre-train은 general한 정보를 학습하는 과정이고 fine-tune은 이러한 모델을 특정 task에 특화되도록 맞추는(세밀한 정보를 학습하는) 과정이기 때문에 pre-training 시보다 더 높은 해상도의 이미지를 사용한다.

Pre-train 시에 사용한 position embedding을 사용할 수 없다. → 해상도가 바뀌었기 때문에 grid의 개수가 달라짐

- 이 문제를 해결하기 위해 2D interpolation을 position embedding에 사용해준다.

⇒ 이러한 resolution adjustment와 patch extraction은 유일하게 2D structure의 inductive bias가 추가되는 부분이다.

Experiments

▼ Setup

Datasets

- Pre-training dataset: ILSVRC-2012 Imagenet, ImageNet-21k, JFT (크기가 점점 커지는 순서)
 - Benchmark tasks: ImageNet, CIFAR-10/100, Oxford-IIIT Pets, Oxford Flowers-102
 - VTAB: 다양한 task에 대해 적은 데이터가 존재할 때 transfer 성능을 평가하는 데이터셋
- 각 task별로 1000 training example을 가지고 natural(자연 이미지), specialized(의료, 위성 영상 등), structured(기하학적 형태)로 나뉜다.

Metrics

- Fine-tuning accuracy: Finetuning을 진행한 후에 accuracy
- Few-shot accuracy: training image의 subset에 대한 representation을 $\{-1, 1\}^K$ 에 매핑하는, 최소 제곱 회귀 문제에 대한 문제에 대한 accuracy 계산
→ 모델 representation이 얼마나 잘 transferable 한지를 측정 가능

Comparison to SOTA

	Ours-JFT (ViT-H/14)	Ours-JFT (ViT-L/16)	Ours-I21k (ViT-L/16)	BiT-L (ResNet152x4)	Noisy Student (EfficientNet-L2)
ImageNet	88.55 ± 0.04	87.76 ± 0.03	85.30 ± 0.02	87.54 ± 0.02	88.4/88.5*
ImageNet ReaL	90.72 ± 0.05	90.54 ± 0.03	88.62 ± 0.05	90.54	90.55
CIFAR-10	99.50 ± 0.06	99.42 ± 0.03	99.15 ± 0.03	99.37 ± 0.06	—
CIFAR-100	94.55 ± 0.04	93.90 ± 0.05	93.25 ± 0.05	93.51 ± 0.08	—
Oxford-IIIT Pets	97.56 ± 0.03	97.32 ± 0.11	94.67 ± 0.15	96.62 ± 0.23	—
Oxford Flowers-102	99.68 ± 0.02	99.74 ± 0.00	99.61 ± 0.02	99.63 ± 0.03	—
VTAB (19 tasks)	77.63 ± 0.23	76.28 ± 0.46	72.72 ± 0.21	76.29 ± 1.70	—
TPUv3-core-days	2.5k	0.68k	0.23k	9.9k	12.3k

Table 2: Comparison with state of the art on popular image classification benchmarks. We report mean and standard deviation of the accuracies, averaged over three fine-tuning runs. Vision Transformer models pre-trained on the JFT-300M dataset outperform ResNet-based baselines on all datasets, while taking substantially less computational resources to pre-train. ViT pre-trained on the smaller public ImageNet-21k dataset performs well too. *Slightly improved 88.5% result reported in [Touvron et al. \(2020\)](#).




Figure 2: Breakdown of VTAB performance in *Natural*, *Specialized*, and *Structured* task groups.

모델

- ViT-H/14, ViT-L/16: 본 논문의 모델
 - H와 L은 모델의 종류, 파라미터 개수를 의미
 - 14와 16은 패치 해상도를 의미하고 patch size가 작을수록 연산량이 많음
- Big Transfer(BiT): 큰 ResNets에 대해 supervised transfer learning을 수행하는 모델
- Noisy Student: large EfficientNet에 대해 semi-supervised learning을 수행한 모델

ImageNet에서 SOTA

결과

ViT-H/14와 ViT-L/16 모두 BiT와 noisy student보다 나은 성능을 보임과 동시에 computational cost도 낮았다.

또한 VTAB 데이터셋의 natural과 structured task에서 ViT-H/14가 BiT와 다른 모델들보다 좋은 성능을 보였고 specialized task에서는 상위 2개의 모델이 유사한 성능을 보였다.

Pre-training data requirements

데이터 셋 크기의 따른 비교 - 서로 다른 데이터셋




Figure 3: Transfer to ImageNet. While large ViT models perform worse than BiT ResNets (shaded area) when pre-trained on small datasets, they shine when pre-trained on larger datasets. Similarly, larger ViT variants overtake smaller ones as the dataset grows.




Figure 4: Linear few-shot evaluation on ImageNet versus pre-training size. ResNets perform better with smaller pre-training datasets but plateau sooner than ViT, which performs better with larger pre-training. ViT-b is ViT-B with all hidden dimensions halved.

ViT는 큰 데이터셋에서 pre-training되었을 때 좋은 성능을 보인다. → ResNet보다 적은 inductive bias를 가지기 때문이다.

- ImageNet(가장 작은 크기)에서는 ViT-Large model이 ViT-Base model보다 낮은 성능을 보였다.
- ImageNet-21k에서도 위와 유사한 성능을 보였다.
- JFT-300M을 사용했을 때만 큰 모델의 이점을 최대한 활용할 수 있었다.

데이터 셋 크기의 따른 비교 - 같은 데이터셋의 subset

Few-shot linear accuracy를 사용해 표현

작은 데이터셋을 사용할 경우 ResNet이 더 좋은 성능을 보인다.

⇒ CNN의 inductive bias가 데이터가 적을 때는 큰 역할을 하고, 큰 데이터셋을 사용할 경우 연관성이 있는 패턴을 모델이 학습하는 것이 더 중요하다.

Scaling study




Figure 5: Performance versus pre-training compute for different architectures: Vision Transformers, ResNets, and hybrids. Vision Transformers generally outperform ResNets with the same computational budget. Hybrids improve upon pure Transformers for smaller model sizes, but the gap vanishes for larger models.

Transfer performance를 비교해 진행한다.

- ViT가 ResNet보다 2배에서 4배 적은 computation을 사용해 같은 성능에 도달할 수 있다.
- Hybrid가 작은 연산량에서 미세하게 성능이 좋다.
- ViT는 포화되지 않는다.

Inspecting Vision Transformer




Figure 7: **Left:** Filters of the initial linear embedding of RGB values of ViT-L/32. **Center:** Similarity of position embeddings of ViT-L/32. Tiles show the cosine similarity between the position embedding of the patch with the indicated row and column and the position embeddings of all other patches. **Right:** Size of attended area by head and network depth. Each dot shows the mean attention distance across images for one of 16 heads at one layer. See Appendix D.7 for details.

- 각 패치의 저차원 representation의 plausible basis function과 유사하다.
- 같은 row와 column에 있는 patch들은 비슷한 embedding을 가진다.

Position embedding이 2D 이미지 topology를 나타내는 방법을 학습하기 때문에, hand-crafted 2D-aware embedding이 의미가 없다.

Self-supervision

Masked patch prediction for self-supervision을 수행해서 large scale self-supervised pre-training의 성능을 평가한다. → BERT의 masked language modeling을 흉내

ViT-B/16 모델이 ImageNet에서 79.9% 정확도를 달성했다. 이는 from scratch (아무런 pre-training 없이 학습) 대비 +2% 성능 향상이지만 여전히 **supervised pre-training (라벨 있는 대규모 데이터로 학습)보다는 4% 낮음.

Summary

- ViT는 이미지를 patch 시퀀스로 나누어 NLP용 Transformer encoder로 처리하는 간단한 아이디어를 제안함.
- CNN처럼 이미지 특화 inductive bias를 넣지 않고도, 대규모 데이터셋에서 pre-training 하면 높은 성능을 달성.
- ImageNet 등에서 최신 CNN과 맞먹거나 뛰어넘는 결과를 보임.

- 하지만 detection, segmentation 같은 다른 비전 과제 적용과 self-supervised 학습의 한계는 남아 있음.
- 모델과 데이터셋을 더 크게 scaling하면 성능이 더 향상될 가능성을 제시.